

AC-DC Sertifika Konsolu

Konsol Üzerinden Adım Adım Anlatım,
Kavramsal Arka Plan, Parametre Etkileri ve
Literatür Detayları

Büyük Veri-Yüksek Lisans Proje2

Haziran 2026

İçindekiler

İçindekiler.....	2
1. Giriş	Hata! Yer işareti tanımlanmamış.
2. Konsolün Anatomisi	3
3. Panel: contract.yaml (Sözleşme).....	3
4. Panel: Ölçülen Değişmezler (Tolerans Rayları).....	4
4.1 Demografik Parite ve Equalized Odds	4
4.2 Vekil Sızıntı AUC: Sunumun En Öğretici Rayı	4
4.3 Provenance ve Rıza Rayları	4
5. Panel: Inference Guardrail (Canlı Deneme)	5
6. Panel: Hesaplama Ek Yüğü.....	6
7. Panel: Yayın Hattı, Attestation, Katalog ve Erişim	6
7.1 Konsey Linti: Sözleşmelerin Sözleşmesi	6
7.2 İmzalı Attestation: Kanıtın Atomikliği	7
7.3 Katalog Defteri ve Amaç-Koşullu Erişim.....	7
8. Senaryoların Pedagojisi	7
9. Olası Sorulara Hazırlık	7
10. Literatür Detayları ve Çalışmadaki Rollerini	8
11. Kapanış Konuşması	10
Kaynaklar	10

1. Giriş

Data Mesh, veriyi domain ekiplerinin sahip olduğu sözleşmeli bir ürüne dönüştürür ve küresel kuralları federatif hesaplamalı yönetimle, yani kod olarak uygular [7]. Üretken yapay zekâ bu modelin denetim nesnesini değiştirdi: artık ‘şema doğru mu’ değil, ‘bu veriyle eğitilen model adil mi, her satırın rızası var mı, üretilen yanıt güvenli mi’ sorularını makineye sordurmamız gerekiyor. Ekrandaki AC-DC sözleşmesi bu soruları nicel, imzalı ve otomatik doğrulanabilir taahhütlere çevirir; ekrandaki konsol da bu sözleşmenin canlı halidir: solda politika, sağda ölçüm, altta yayın ve erişim zinciri.”

Ödevden anlaşılması gereken: Yönetişimin yapısal şemalardan (SQL kısıtları, JSON Schema) davranışsal/etik değişimlere genişlemesi; bunun nedeni ihlal biriminin değişmesidir: klasik kısıt tek satırda doğrulanır (deterministik), parite veya toksisite ise bir dağılımın özelliğidir ve istatistiksel kestirim, referans görev ve örneklem gerektirir. Bu tek cümle, sunumun bütün mimari kararlarının (katman ataması, iki kademeli denetim, attestation) kökenidir.

Literatür bağı: Dehghani [7] federatif hesaplamalı yönetişimi tanımlar; DeeQu [2] ‘veri için birim test’ fikriyle bildirimsel kısıtların ölçekli otomatik doğrulamasını kurar (Amazon’da Spark üzerinde, artımlı metrik hesabıyla); Datasheets [4] ve Model Cards [3] etik beyan çerçevesini getirir ancak insan-okunurdur. AC-DC, [4] ve [3]’ün beyanlarını [2]’nin makine-doğrulanabilir biçimine taşıyan kesişimdir — sunumda bu cümleyi aynen kullanın.

2. Konsolün Anatomisi

Ekran üç bölgeden oluşur ve yerleşim, analizin kavramsal ayrımını birebir kodlar. Sol kolon politika ve yaptırım tarafıdır: düzenlenebilir sözleşme (contract. yaml), istek-başına guardrail deneme alanı ve hesaplama ek yükü kartları. Sağ kolon ölçüm tarafıdır: altı değişimin tolerans rayları, her rayın katman etiketi (mor mesh, amber giriş kapısı, mavi inference) ve seçili senaryoya göre değişen case açıklamaları. Alt bölge ise yayın hattıdır: konsey linti, imzalı attestation, özet-zincirli katalog defteri ve amaç-koşullu erişim kapısı. Sunumun tek cümlelik kullanım kılavuzu: “solda ne değiştirirsem sağda yargı, altta yayın kararı değişir.” Sağ üstteki damga (CERTIFIED/QUARANTINED) yerel görünümdür; alt bölgedeki yayın, konseyin küresel kurallarından da geçmek zorundadır — bu ikilik kasıtlıdır ve federatif yönetişimin iki seviyesini temsil eder.

3. Panel: contract. yaml (Sözleşme)

Ekran: Üç vektör bloğu (algorithmic_bias, provenance_and_consent, behavioral_safety), her satırda düzenlenebilir sınır değeri ve yorum satırındaki katman ataması.

Bilgi: Sözleşme bir politika-kod (policy-as-code) artefaktıdır: her kısıt metrik + operatör + sayısal sınırdan oluşur, ‘adil ol’ gibi ölçülemez ifade barındırmaz. Eşiklerin kaynağı bilinçli olarak heterojendir: parite sınırı (0,05) istihdam hukukundaki 4/5 kuralı kalibrasyonudur; rıza sınırı (== 1,00) hukukidir ve bölünemezdir; vekil AUC sınırı (0,60) bilgi-kuramsaldır (0,50 = rastgele tahmin); örneklem tabanı istatistiksel güç koşuludur. Operatör seçimi bile anlam taşır: toleranslı kısıtlar <= />= ile, bölünemez hukuki kısıt == ile yazılır.

Örnekleme: ‘rıza için neden 0,99 değil 1,00?’ Cevap: yüzde 99 rızalı RLHF veri seti diye bir şey yoktur; kalan yüzde 1 KVKK/GDPR ihlalidir. Parite ise toleranslıdır çünkü istatistiksel kestirimdir ve örneklem gürültüsü taşır — iki kısıt türünün epistemolojisi farklıdır.

Literatür bağı: DeeQu [2] aynı bildirimsel yapıyı veri kalitesi için kurar (completeness, uniqueness gibi kısıtlar); AC-DC bu yapıyı hizalama metriklerine genişletir. Model Cards [3] metriklerin gruplara ayrıştırılmış (disaggregated) raporlanmasını önerir; sözleşmedeki protected_attributes listesi bu fikrin zorunlu kılınmış halidir.

4. Panel: Ölçülen Değişmezler (Tolerans Rayları)

Ekranda: Sekme değişiminde rayların ve case kutularının güncellenişi; yeşil bölge = izin aralığı, ok = ölçülen değer, kutu rengi = senaryo (kırmızı A, amber B, yeşil C).

4.1 Demografik Parite ve Equalized Odds

Demografik parite farkı, korunan gruplar arası pozitif karar oranı farkıdır: $|P(\hat{Y}=1|A=a) - P(\hat{Y}=1|A=b)|$. Tek başına yanıltıcı olabilir: bir model her gruba eşit oranda onay verip hatalarını tek grupta yoğunlaştırabilir. Hardt, Price ve Srebro [1] bu boşluğu equalized odds ile kapatır: doğru pozitif ve yanlış pozitif oranlarının gruplar arasında eşitlenmesini ister ve herhangi bir tahmincinin üzerine, tahminciyi yeniden eğitmeden uygulanabilen bir son-işleme (post-processing) yöntemi verir — pilottaki Senaryo B’nin grup-bazlı eşik kalibrasyonu tam bu yöntemin uygulamasıdır. Sunumda A sekmesinde iki değeri birlikte okuyun: parite 0,2053 ve odds 0,3489 — model hem onay oranında hem hata dağılımında ayrımcıdır; B’de ikisi birden düşer (0,0203 ve 0,0076), çünkü kalibrasyon her iki yüzeyi de düzeltir.

4.2 Vekil Sızıntı AUC: Sunumun En Öğretici Rayı

‘Korunan niteliği tablodan sileriz, olur biter’ yaklaşımı literatürde fairness through unawareness olarak bilinir ve Dwork vd. [9] tarafından yetersizliği gösterilmiştir: korunmayan alanlar (posta kodu, alışveriş örüntüsü) korunan niteliği yeniden kodlayabilir (redundant encoding). Sözleşmedeki proxy_leakage_auc değişmezi bu riski nicelleştirir: her doğrulama koşulunda bir denetim sondası (lojistik regresyon) korunmayan alanlardan korunan niteliği tahmin etmeye çalışır; AUC 0,50 rastgele tahmin, yüksek AUC sızıntı demektir. Sunum anı: B sekmesinde parite ve odds yeşilken vekil rayının 0,7924 ile tek kırmızı kaldığını gösterin ve cümleyi kurun: ‘tahminleri düzeltmek, verinin özneliliklerine işlemiş önyargıyı gidermez; bu değişmez olmasaydı port hatalı sertifikalanacaktı.’ C’de aynı ray 0,4979’a iner, çünkü posta bölgesi cinsiyetten bağımsız genel bölgelere genelleştirilmiştir — bu, Sweeney’nin k-anonimlik çerçevesindeki [8] genelleme (generalization) operasyonunun bire bir uygulamasıdır: posta kodu klasik bir yarı-tanımlayıcıdır (quasi-identifier) ve kaba taneye çekilmesi yeniden-tanımlama/sızıntı riskini düşürür.

4.3 Provenance ve Rıza Rayları

Bu iki ray giriş kapısı (amber) etiketlidir, çünkü satır düzeyinde deterministik kontrol edilebilirler ve örnekleme kabul etmezler: == 1,00 koşulu, örneklemede görünmeyen tek bir rızasız satırla bile ihlal edilebileceği için tam tarama gerektirir. Datasheets [4] bu bilgilerin (toplama koşulları,

rıza, ön işleme) belgelenmesini insan-okunur sorularla ister; AC-DC aynı bilgiyi satır-düzeyi makine kontrolüne çevirir ve geri çekme için 72 saatlik yayılım SLA'sı tanımlar.

Parametre oyunu	Değişim	Konsoldaki etkisi	Öğrettiği
Parite sınırı	0,05 → 0,02	Senaryo B'nin paritesi (0,0203) 0,0003 farkla FAIL'e düşer	Eşik marjinal kararları çevirir; seçim normatiftir [5]
Parite sınırı	0,05 → 0,25	A'nın paritesi bile PASS olur; yayın denenirse konsey linti META-003 (tavan 0,10) ile PR'ı reddeder	Yerel gevşetme küresel tavana çarpar
Vekil AUC sınırı	0,60 → 0,49	Senaryo C (0,4979) kıl payı karantinaya düşer; 0,50'de geri döner	En iyi senaryo bile sınıra görelidir
Vekil AUC sınırı	0,60 → 0,80	B sertifikalanır = sızıntı bilerek kabul; yayında META-006 (tavan 0,65) durdurur	Sorumluluk görünür kılınır, yok edilmez
Provenance sınırı	0,98 → 0,94	A'nın kapsamı (0,949) geçer; kökeni belirsiz %5 RLHF'e akar	Sınır gevşetmenin somut bedeli
Rıza kapsamı	1,00 → 0,9603	A'nın rızası 'geçer'; yayında POL-101 reddeder	Hukuki kısıt yerel olarak oynanabilir, küresel olarak oynanamaz
block_threshold	0,50 → 0,70	0,60 skorlu yanıt BLOCKED'dan ALLOWED'a; $\hat{P}$ ihlali sürer, tavan 0,70 (POL-105)	Ölçüm-yaptırım ayrımı
Toksisite sınırı	0,001 → 0,008	A'nın ham oranı (0,00715) 'uyumlu' görünür	Dağılımsal korumanın boşaltılması

5. Panel: Inference Guardrail (Canlı Deneme)

Ekranda göster: Temiz yanıt → ALLOWED 0,00; 'Bu başvuru salakça sorularla dolu.' → BLOCKED 0,60; block_threshold 0,70 → aynı cümle ALLOWED; üç tekrar → nabız şeridi kırmızıyla dolar ve $\hat{P} = 0,800 > 0,001$ uyarısı yatar; 'aptal + rezil' cümlesi → 1,00, 0,70'te bile BLOCKED.

Anlatılacak bilgi: Guardrail, modelin ağırlıklarını değiştirmeden çıktığı çalışma zamanında denetleyen katmandır. Buradaki kritik tasarım ölçüm-yaptırım ayrımıdır: değişmez ölçüm eşiği (0,5) metrik tanımının parçasıdır ve sabittir; bloklama eşiği operasyonel politikadır ve ayarlanabilir. Nabız şeridi, kayan pencere kestirimcisinin görselidir: dağılımsal bir metrik tek istekte tanımsız olduğundan, inference katmanı ancak böyle bir kestirimle (gecikmeli,

varyanslı) dağılıma yaklaşabilir — adalet metrikleri içinse alt-grup trafiği yetersiz kalacağından bu bile mümkün değildir; o yüzden mesh katmanı vazgeçilmezdir.

Literatür bağı: NeMo Guardrails [6] bu katmanın endüstriyel referansıdır: Colang adlı bir DSL ile girdi rayları (jailbreak tespiti), çıktı rayları (toksisite, konu denetimi), retrieval ve araç-çağrısı rayları programlanır; akış, kullanıcı niyetinin gömme-tabanlı eşleştirilmesiyle yönetilir ve her ray ek sınıflandırıcı/LLM çağrısı maliyeti getirir — ek yük kartlarındaki '50–300 ms/istek' değerinin kaynağı budur. Llama Guard tarzı öğrenilmiş denetçiler ise esnektir ama kendileri istatistikselidir: FAccT literatürü toksisite sınıflandırıcılarının azınlık lehçelerini orantısız işaretleyebildiğini belgeler; sözleşmede sınıflandırıcı sürümünün sabitlenmesi (tox-stub v0.1) bu hatayı yok etmez, tekrarlanabilir ve denetlenebilir kılar. Pilot geliştirme sürecinde skorlayıcının ilk sürümündeki bir alt-dizgi hatasının ('salakça' içindeki 'salak'ın çift sayılması) davranışı sessizce değiştirmesi, bu ilkenin yaşanmış kanıtı olarak anlatılabilir.

6. Panel: Hesaplama Ek Yükü

Üç kart, iki denetim noktasının maliyet karakterini kıyaslar: mesh doğrulaması sürüm başına bir kez koşar, kritik yol dışındadır ve satır başına mikrosaniye mertebesinde amorti edilir (pilotta 4–10 µs/satır); guardrail maliyeti her isteğe eklenir ve trafikle çarpılır — stub mikrosaniye sürer ama gerçek bir LLM-rayı istek başına 50–300 ms ve ek token maliyeti getirir, seri bağlanan raylarda gecikme toplanır. Anlatılacak mimari sonuç: dağılımsal ve rıza/provenance değişmezleri 'sola' (yayın ve giriş anına) kaydırılmalı, inference bütçesi yalnızca mesh'in ilkesel olarak göremeyeceği bağlamsal/davranışsal risklere ayrılmalıdır. Deequ'nun [2] tasarım gerekçesi de aynıdır: kaliteyi tüketim anında değil, veri üretim hattında, toplu ve artımlı doğrulamak.

7. Panel: Yayın Hattı, Attestation, Katalog ve Erişim

Ekranda göster: Altı adımlı zincir (PR → Konsey linti → Doğrulama → Attestation → Katalog → Erişim). Demo akışı: (1) C sekmesinde 'Portu yayımla' → altı adım yeşil, attestation kartı ve katalog kaydı oluşur; (2) 'Attestation'ı kurcala' → kart kırmızılaşır, erişim isteği 'imza uyuşmuyor' ile DENY; (3) yeniden yayımla → rlhf amacıyla GRANT, ancak cinsiyet ve yas_grubu sütunları üstü çizili (maskelenmiş); (4) redistribution amacı → DENY; (5) A sekmesinde yayımla → katalogda QUARANTINED kaydı, her amaç DENY; (6) sınırları TC-A4 gibi veriye uydurup yayımlamayı dene → damga yeşilken konsey linti META-003 ve POL-101'den PR'ı reddeder.

7.1 Konsey Linti: Sözleşmelerin Sözleşmesi

Lint, domain sözleşmesinin metnini konseyin meta-şemasına karşı denetler; veriye hiç bakmaz. İki kural sınıfı vardır: yapısal (zorunlu bloklar, eşik tavanları — META-003 parite tavanı 0,10; META-006 vekil tavanı 0,65) ve alanlar-arası politika (POL-101: RLHF amacı varsa rıza == 1,00; POL-105: bloklama eşiği tavanı 0,70). Anlatılacak kilit fikir: meta-şemanın kendisi konseyin deposunda sürümlü bir artefaktır; konsey küresel politikayı değiştirmek için hiçbir domain deposuna dokunmaz, meta-şemayı günceller ve bütün sözleşmeler yeniden lintlenir — politika yayılımının 'hesaplamalı' olması budur. Demo 6'daki an sunumun zirvesidir:

yerel damgayı kandırabilen yönetim teslimiyeti, küresel lint duvarına çarpar; federatif modelin iki seviyesi (domain özerkliği + konsey çerçevesi) tek tıkta görünür olur.

7.2 İmzalı Attestation: Kanıtın Atomikliği

Attestation şu cümlelerin imzalı halidir: 'doğrulayıcı V, T anında, S sözleşmesini (içerik özeti) D verisine (içerik özeti) karşı koşturdu, M metriklerini ölçtü ve X kararını verdi.' İmza kanonik serileştirilmiş gövdenin bütünü üzerinden hesaplandığından hiçbir alan tek başına değiştirilemez — kurcalama demosunda kararın elle çevrilmesinin erişim kapısında imza uyumsuzluğuyla yakalanması bunu gösterir. Kavramsal akrabaları yazılım tedarik zinciri güvenliğindedir: in-toto/SLSA provenance beyanları ve sigstore/cosign anahtarsız imzalama. Dürüstlük notu olarak ekleyin: pilottaki özet bütünlük sağlar ama özgünlük sağlamaz; üretimde asimetrik imza ve Rekor benzeri şeffaflık günlüğü gerekir.

7.3 Katalog Defteri ve Amaç-Koşullu Erişim

Katalog, mantıksal port URI'sini fiziksel konuma, sözleşme özetine ve attestation'a bağlayan çözümleme noktasıdır; tüketici fiziksel yolu asla bilmez, bu dolaylama karantinaya yaptırım gücü verir (veri silinmez, kayıt çevrilir). Defter salt-ekleme ve özet-zincirlidir (her kayıt öncekinin özetini taşır) — sertifika şeffaflığı (Certificate Transparency) fikrinin mesh uyarlaması; geçmiş sessizce yeniden yazılamaz. Erişim kapısı ise KVKK/GDPR'daki amaç sınırlılığı ilkesinin hesaplamalı karşılığıdır: iş yükü kimliği + kontrollü sözlükten amaç beyanı; kapı attestation geçerliliğini, CERTIFIED durumunu ve amacın allowed_purposes kümesinde olduğunu doğrular, kısa ömürlü ve amaç-damgalı bir kimlik keser. Sütun maskeleyme demosu, sözleşmedeki conditioning_on_protected_attributes yasağının yaptırımıdır: eğitim amaçlı erişim korunan sütunları fiziksel olarak göremezken, fairness_audit amacı tam kapsam alır — denetçi pariteyi ölçmek için gruplara muhtaçtır. Dürüst sınır: amaç beyanı bir iddiadır (amaç aklama riski); mesh'in kapanışı, tüketicinin de üretici olmasıdır — uyumsuz amaçla okunmuş kaynak, tüketicinin kendi yayın anındaki soyağacı denetiminde görünür.

8. Senaryoların Pedagojisi

Üç senaryo aynı 20.000 kişilik sentetik popülasyonun müdahale zincirindeki üç aşamasıdır ve kademe kasıtlıdır: tek senaryoda her şey birden düzelseydi hangi sözleşme kontrolünün neyi yakaladığı gözlemlenemezdi. A (ham): gizli skor bonusu, korele posta bölgesi, eksik rıza/provenance, toksik yanıtlar — denetimsiz ürünün varsayılan hali, 6/6 FAIL. B (kalibrasyon): Hardt-tarzı [1] grup-bazlı eşik son-işlemesi + giriş filtresi; beş değişmez düzelir, vekil AUC 0,79'da kalır — 'tahmini düzeltmek veriyi düzeltmek değildir.' C (minimizasyon): vekil alanın k-anonimlik tarzı [8] genelleştirilmesi; AUC rastgele düzeye iner, 6/6 PASS, imzalı attestation. Tek cümlelik özet: 'A sorun, B yarım çözüm ve tuzağı, C tam çözüm — sözleşmenin değeri, B'yi C sanmamızı engellemesidir.'

9. Olası Sorulara Hazırlık

Beklenen soru	Cevap anahtarı
Neden iki katman? Her şeyi inference'ta denetlesek olmaz mı?	İki nedenle olmaz. İlkesel: grup adaleti dağılımının özelliğidir, tek istek üzerinde tanımsızdır; inference'taki en iyi yaklaşım kayan pencere kestirimidir, o da alt-grup trafiği için istatistiksel güçten yoksundur. Ekonomik: guardrail maliyeti trafikle çarpılır (gerçek rayda 50–300 ms/istek [6]); mesh maliyeti sürüm başına amorti edilir (µs/satır).
Hangi adalet metriği 'doğru'?	Hiçbiri evrensel olarak. Kleinberg vd. [5] kalibrasyon ile grup-bazlı hata-oranı dengelerinin, taban oranları farklıyken aynı anda sağlanamayacağını kanıtlar. Metrik seçimi normatiftir; sözleşmenin katkısı seçimi şeffaf, sürümlü ve hesap verilebilir kılmaktır — bu yüzden adalet eşikleri CODEOWNERS ile konsey onayına bağlıdır.
Tüketici amacını yalan beyan ederse?	Erişim anında beyan bir iddiadır; teknik olarak tam engellenemez (amaç aklama). Üç savunma katmanı: iş yükü kimliği + amaç-damgalı denetim günlüğü; mesh'te tüketicilerin de üretici olması — uyumsuz amaçla okunmuş kaynak, tüketicinin kendi yayınındaki soyağacı denetiminde yakalanır; ve sözleşmesel/hukuki sorumluluk.
Sentetik veriyle bulgular ne kadar genellenebilir?	Pilot, sayıların değil mimarinin kanıtıdır: metrik hesaplayıcılar (parite, odds, AUC) gerçek veride birebir aynıdır. Sentetik kurgu, ihlalleri kontrollü enjekte edip her kontrolün neyi yakaladığını izole etmeyi sağlar. Sınırlılıklar bölümünde nokta tahmin / güven aralığı ve stub skorlayıcı açıkça beyan edilmiştir.
%96 rıza neden yetmiyor?	Rıza hukuki ve bölünemez bir kısıttır: kalan %4 KVKK/GDPR ihlalidir. Bu yüzden operatör eşitliktir (== 1,00), kontrol örneklemsiz tam taramadır ve yaptırım satır reddidir; konsey linti (POL-101) yerel gevşetmeyi küresel düzeyde de engeller.
Guardrail'in kendisi önyargılıysa?	Gerçek bir risk: FAccT literatürü toksisite sınıflandırıcılarının azınlık lehçelerini orantısız işaretleyebildiğini gösterir. Sözleşme bunu çözmez ama yönetilebilir kılar: sınıflandırıcı adı ve sürümü sabitlenir, davranış değişikliği sürüm değişikliği olarak görünür olur; pilota skorlayıcı hatasının tespiti bunun yaşanmış örneğidir.

10. Literatür Detayları ve Çalışmadaki Roller

[1] **Hardt, Price, Srebro — Equality of Opportunity in Supervised Learning (NeurIPS 2016)**. Equalized odds ve equal opportunity ölçütlerini tanımlar: tahminin, gerçek etikete koşullandığında korunan nitelikten bağımsız olmasını ister (TPR ve FPR eşitliği). Önemli katkısı, herhangi bir eğitilmiş tahmincinin üzerine uygulanabilen, modeli yeniden eğitmeyen bir son-işleme yöntemidir; yalnızca (tahmin, etiket, grup) üçlüsüne bakar. Çalışmadaki rolü: equalized_odds_gap değişiminin tanımı ve Senaryo B'deki grup-bazlı eşik kalibrasyonunun yöntemsel temeli.

[2] **Schelter vd. — Automating Large-Scale Data Quality Verification (PVLDB 2018)**. Amazon'da geliştirilen Deequ sistemini sunar: kullanıcı bildirimsel kısıtlar yazar ('veri için birim

test'), sistem bunları Spark üzerinde ölçekli metriklerle derler, büyüyen veri için artımlı hesap yapar ve kısıt önerisi üretir. Çalışmadaki rolü: mesh-katmanı doğrulayıcısının sistem modeli — bildirimsel kısıt, toplu/amorti doğrulama ve yayın-öncesi kalite kapısı fikirlerinin kaynağı; AC-DC bu çatıyı kalite metriklerinden hizalama metriklerine genişletir.

[3] Mitchell vd. — Model Cards for Model Reporting (FAT*/FAccT 2019). Modeller için standart rapor çerçevesi önerir: amaçlanan kullanım, etkileyen faktörler, gruplara ayrıştırılmış değerlendirme metrikleri, değerlendirme verisi ve etik mülahazalar. Çalışmadaki rolü: 'gruplara ayrıştırılmış değerlendirme' ilkesi protected_attributes alanının gerekçesidir; AC-DC, Model Cards'ın beyanlarını imzalı ve makine-doğrulanabilir attestation'a dönüştürür.

[4] Gebru vd. — Datasheets for Datasets (CACM 2021). Elektronik bileşen veri sayfalarından esinle, her veri seti için standart soru kümesi önerir: motivasyon, kompozisyon, toplama süreci (rıza dahil), ön işleme, kullanım, dağıtım ve bakım. Çalışmadaki rolü: provenance_and_consent vektörünün beyan-katmanı atası; AC-DC bu beyanları satır-düzeyi kontrole (kapsam oranları, geri çekme SLA'sı) çevirir.

[5] Kleinberg, Mullainathan, Raghavan — Inherent Trade-Offs in the Fair Determination of Risk Scores (ITCS 2017). Risk skorları için üç doğal adalet koşulunun (kalibrasyon; pozitif sınıfta denge, negatif sınıfta denge) ancak taban oranları eşitse veya tahmin mükemmelse aynı anda sağlanabileceğini kanıtlar; Chouldechova'nın eşzamanlı sonucuyla birlikte COMPAS tartışmasının matematiksel zeminidir. Çalışmadaki rolü: eşik ve metrik seçiminin normatifliği savının biçimsel dayanağı; sözleşmenin 'adaleti çözme' değil 'adalet kararını şeffaflaştırma' iddiasının gerekçesi.

[6] Rebedea vd. — NeMo Guardrails (EMNLP 2023, System Demonstrations). LLM uygulamaları için açık kaynak, programlanabilir ray çerçevesi: Colang DSL ile diyalog akışları ve raylar (girdi/çıktı güvenliği, konu denetimi, retrieval ve araç rayları) tanımlanır; kullanıcı niyeti gömme tabanlı eşleştirilir, raylar çalışma zamanında ek model çağrılarını yapar. Çalışmadaki rolü: inference-katmanı yaptırımının referans mimarisi ve istek-başına gecikme/maliyet profilinin (ek yük kartları) kaynağı.

[7] Dehghani — Data Mesh (O'Reilly 2022). Dört ilkeyi sistemleştirir: domain sahipliği, ürün olarak veri, self-servis platform, federatif hesaplamalı yönetim; output portu, veri ürünü ve küresel politikaların platformda kod olarak uygulanması kavramlarını tanımlar. Çalışmadaki rolü: bütün mimari çerçeve; AC-DC, dördüncü ilkenin üretken-YZ çağına genişletilmesidir.

[8] Sweeney — k-Anonymity: A Model for Protecting Privacy (2002). Yarı-tanımlayıcılar (posta kodu, doğum tarihi, cinsiyet) üzerinden yeniden-tanımlama riskini gösterir ve genelleme/bastırma operasyonlarıyla her kaydın en az k kayıttan ayırt edilemez kılınmasını önerir. Çalışmadaki rolü: Senaryo C'deki müdahalenin (posta bölgesinin genelleştirilmesi) yöntemsel temeli; vekil sızıntısı ile yeniden-tanımlama riskinin akrabalığını kurar.

[9] Dwork vd. — Fairness Through Awareness (ITCS 2012). Bireysel adalet çerçevesini kurar ('benzer bireylere benzer davran') ve körlük yaklaşımının (fairness through unawareness) vekil değişkenler nedeniyle yetersizliğini gösterir. Çalışmadaki rolü:

proxy_leakage_auc değışmezinin kavramsal gerekçesi — niteliđi silmek yetmez, sızıntı ölçülmelidir.

11. Kapanış

“Özetle: sözleşme bir belge deđil, çalışan bir denetçidir. Solda görünen her sayı bir yönetim kararıdır — kimi mühendislik kalibrasyonu, kimi hukuk, kimi konseyin normatif tercihi; sağdaki raylar bu kararların veriye karşı sürekli yargılanmasıdır; alttaki zincir ise hiçbir kararın sessizce alınamayacağıının garantisidir: lint küresel çerçeveyi, imza kanıtın bütünlüğünü, zincirli katalog tarihin değışmezliğini, amaç-damgalı erişim de kullanımın sınırını tutar. Sistem yanlış kararları engellemez; onları görünür, sürümlü ve hesap verilebilir kılar. İmzalı sertifikanın iddiası da bilinçli olarak mütevazıdır: ‘bu veri adildir’ demez; ‘bu baytlar üzerinde, bu sözleşmenin seçtiđi metrikler, bu tarihte, bu sınırların içindeydi’ der.”

Kaynaklar

- [1] Hardt, M., Price, E., Srebro, N. (2016). Equality of Opportunity in Supervised Learning. NeurIPS 2016.
- [2] Schelter, S., Lange, D., Schmidt, P., Celikel, M., Biessmann, F., Grafberger, A. (2018). Automating Large-Scale Data Quality Verification. PVLDB 11(12).
- [3] Mitchell, M., Wu, S., Zaldivar, A. vd. (2019). Model Cards for Model Reporting. FAT*/FAccT 2019.
- [4] Gebru, T., Morgenstern, J., Vecchione, B. vd. (2021). Datasheets for Datasets. Communications of the ACM 64(12).
- [5] Kleinberg, J., Mullainathan, S., Raghavan, M. (2017). Inherent Trade-Offs in the Fair Determination of Risk Scores. ITCS 2017.
- [6] Rebedea, T., Dinu, R., Sreedhar, M., Parisien, C., Cohen, J. (2023). NeMo Guardrails: A Toolkit for Controllable and Safe LLM Applications with Programmable Rails. EMNLP 2023 (System Demonstrations).
- [7] Dehghani, Z. (2022). Data Mesh: Delivering Data-Driven Value at Scale. O'Reilly Media.
- [8] Sweeney, L. (2002). k-Anonymity: A Model for Protecting Privacy. International Journal of Uncertainty, Fuzziness and Knowledge-Based Systems 10(5).
- [9] Dwork, C., Hardt, M., Pitassi, T., Reingold, O., Zemel, R. (2012). Fairness Through Awareness. ITCS 2012.

ÖNEMLİ:

TEYİT künyeleri (DOI, sayfa) kütüphane veritabanından teyit edin; [1], [2], [3] ödev şartındaki NeurIPS/VLDB/FAccT koşulunu karşılayan hakemli yayınlardır.