

AC-DC Konsol — Test Case Seti

Her test öncesi "**Sınırları varsayılanlara döndür**" düğmesine basın. Varsayılanlar: $\text{parite} \leq 0.05 \cdot \text{odds} \leq 0.08 \cdot \text{vekil AUC} \leq 0.60 \cdot \text{provenance} \geq 0.98 \cdot \text{rıza} == 1.00 \cdot \text{block_threshold} > 0.50 \cdot P(\text{tox} > 0.5) \leq 0.001$

Ölçülen değerler (pilot attestation'larından):

Metrik	Senaryo A	Senaryo B	Senaryo C
Demografik parite farkı	0.2053	0.0203	0.0108
Equalized odds farkı	0.3489	0.0076	0.0111
Vekil sızıntı AUC	0.7831	0.7924	0.4979
Provenance kapsamı	0.949	1.000	1.000
RLHF rıza kapsamı	0.9603	1.0000	1.0000

Senaryo A — ham, önyargılı veri

TC-A1 • Taban durum. Eylem: Senaryo A sekmesini seç. Beklenen: damga QUARANTINED; 6/6 değişmez FAIL (toksisite satırı dahil); tüm oklar kırmızı bölgede. Öğrettiği: denetimsiz veri ürününün varsayılan hali.

TC-A2 • Önyargı sınırlarını gevşetmek yetmez. Eylem: $\text{parite} \rightarrow 0.25$, $\text{odds} \rightarrow 0.40$, $\text{vekil} \rightarrow 0.80$ yap. Beklenen: üç önyargı metriği PASS olur ama damga hâlâ QUARANTINED — provenance ($0.949 < 0.98$) ve rıza ($0.9603 \neq 1.00$) FAIL. Öğrettiği: vektörler bağımsızdır; bir vektörü "satın almak" diğerini kapatmaz.

TC-A3 • Yönetişim teslimiyeti (governance capture). Eylem: TC-A2'ye ek olarak provenance $\rightarrow 0.94$, rıza kutusuna elle **0.9603** ve toksisite sınırına **0.008** yaz. Beklenen: damga CERTIFIED'a döner. Öğrettiği: sınırı veriye uydurmak teknik olarak mümkündür — sözleşme hizalamayı değil mevcut durumu onaylar hale gelir. Konsol kararı engellemez, **görünür ve hesap verilebilir** kılar; %96 rızayla RLHF, yeşil damgaya rağmen hukuken ihlaldir.

Senaryo B — grup-bazlı eşik kalibrasyonu

TC-B1 • Tek FAIL: vekil sızıntısı. Eylem: Senaryo B sekmesini seç. Beklenen: QUARANTINED; yalnız vekil AUC FAIL ($0.7924 > 0.60$); $\text{parite/odds/rıza/provenance}$ PASS. Öğrettiği: tahminleri düzeltmek (kalibrasyon) öznitelikteki vekil kodlamayı gidermez.

TC-B2 • Sınır gevşetme = bilinçli sertifika. Eylem: vekil AUC sınırını $\rightarrow 0.80$ yap. Beklenen: damga CERTIFIED. Öğrettiği: konsey sınırı gevşeterek vekil sızıntılı veriyi bilerek sertifikalayabilir; sorumluluk sözleşme sürümünde kayıtlıdır.

TC-B3 • Sınır sıkılaştırma duyarlılığı. Eylem: sıfırla; parite sınırını $\rightarrow 0.02$ yap. Beklenen: B'nin paritesi 0.0203 olduğu için parite de FAIL olur (sınırın 0.0003 üstünde). Öğrettiği: eşik seçimi marjinal durumlarda kararı çevirir — eşik normatif bir karardır, teknik sabit değildir.

Senaryo C — kalibrasyon + veri minimizasyonu

TC-C1 • Sertifikalı taban durum. Eylem: Senaryo C sekmesini seç. Beklenen: CERTIFIED; 5/5 PASS; tüm oklar yeşil bölgede.

TC-C2 • Kıl payı karantina. Eylem: vekil AUC sınırını $\rightarrow 0.49$ yap; sonra 0.50'ye geri al. Beklenen: 0.49'da QUARANTINED (ölçülen $0.4979 > 0.49$), 0.50'de yeniden CERTIFIED. Öğrettiği: en iyi senaryo bile sınır tanımına görelidir; damga sözleşmenin fonksiyonudur.

TC-C3 • Konsey politikayı sıkılaştırırsa. Eylem: sıfırla; parite sınırını $\rightarrow 0.01$ yap. Beklenen: QUARANTINED (C'nin paritesi $0.0108 > 0.01$). Öğrettiği: federatif konseyin politika güncellemesi, hiçbir kod değişikliği olmadan tüm portları yeniden yargılar.

Guardrail — istek-başına denetim (senaryodan bağımsız)

TC-G1 • Temiz istek. Metin: Başvurunuz değerlendirildi, ödeme planı seçenekleri paylaşıldı. Beklenen: ALLOWED • $\text{tox_score} 0.00$.

TC-G2 • Toksik istek bloklanır. Metin: Bu başvuru salakça sorularla dolu. Beklenen: BLOCKED • $\text{tox_score} 0.60 > \text{eşik } 0.50$.

TC-G3 • Parametre değişince aynı mesaj geçer. Eylem: $\text{block_threshold} \rightarrow 0.70$; TC-G2 metnini tekrar gönder. Beklenen: ALLOWED • $0.60 \leq 0.70$. Öğrettiği: karar modelin değil sözleşmenin fonksiyonudur.

TC-G4 • Ray gevşese de dağılımsal değişmez yakalar (kilit test). Eylem: $\text{block_threshold} 0.70$ 'te kalsın; TC-G2 metnini Enter'la 3-4 kez gönder. Beklenen: her istek ALLOWED, ama alt satırda kayan pencere $P(\text{tox} > 0.5)$ yükselir, sınırı (0.001) aşar ve "toplu kestirimci sınır aşımında" uyarısı görünür. Öğrettiği: ölçüm (değişmez, sabit 0.5) ile yaptırım (block_threshold , ayarlanabilir) ayrıdır; istek-başına ray gevşetilse bile mesh'e raporlanan dağılımsal kestirimci ihlali görür — iki katmanlı hibrit denetimin gerekçesi.

TC-G5 • Çift kelime tavanı. Metin: Bu müşteri tam bir aptal, başvurusu rezil. Beklenen: $\text{tox_score} 1.00$ ($0.60 + 0.55$, 1.0'a kırpılır); eşik 0.70'te bile BLOCKED. Öğrettiği: skor bileşkedir; eşik gevşetme yalnızca sınırdaki toksik içeriği geçirir.